Класификация на газове чрез данни от IoT сензорна мрежа

Димитър Николов
Ф.Н.: 471222022, ИСН, 77гр

ВЪВЕДЕНИЕ

Тема и цел на проекта

Контекст

Проектът изследва приложението на машинно обучение върху данни от безжични IoT сензорни мрежи за мониторинг на околната среда.

Конкретна задача

Класификация на вид газ по измервания от масив от 16 химически сензора - с помощта на модели за машинно обучение.

Подход

Обучение и оценка на **Random Forest** модел, с възможност за сравнение с **FastAI Tabular Learner** като deep learning подход за таблични данни.

МОТИВАЦИЯ

Защо темата е важна?

Мониторинг на средата

IoT сензорните мрежи позволяват непрекъснато събиране на данни за качеството на въздуха и състоянието на средата.

Индустриална безопасност

Автоматичното откриване на опасни газове предотвратява аварии и предпазва човешкия живот.

ML решения

Машинното обучение позволява автоматично разпознаване на състояния и подпомага вземането на решения.

ДАННИ

Gas Sensor Array Drift Dataset

13,910

Измервания

Общо записи в датасета

16

Сензора

Химически сензора в масива

128

Характеристики

Числови признаци на запис

6

Класа газове

Различни целеви газове

Газовете в датасета са: **Ethanol**, **Ethylene**, **Ammonia**, **Acetaldehyde**, **Acetone** и **Toluene** - вещества, релевантни за мониторинг на среда, лабораторни измервания и индустриална безопасност.

ПРЕДОБРАБОТКА

Подготовка на данните

Стъпки по обработка

- Данните се свалят като ZIP архив и се парсват от `.dat` файлове
- Формат на записите: `class feature:value`
- Използвани са само признаците `feature_001` до `feature_128`
- Променливата `batch` е изключена, за да не се въвежда изкуствено предимство в модела
- Данните са разделени на training и validation set в съотношение 80/20 със `stratify`, за да се запази разпределението на класовете.

> Изключването на `batch` гарантира, че моделът се учи от реалните сензорни характеристики, а не от метаданни за експеримента.

АНАЛИЗ

Разпределение на класовете

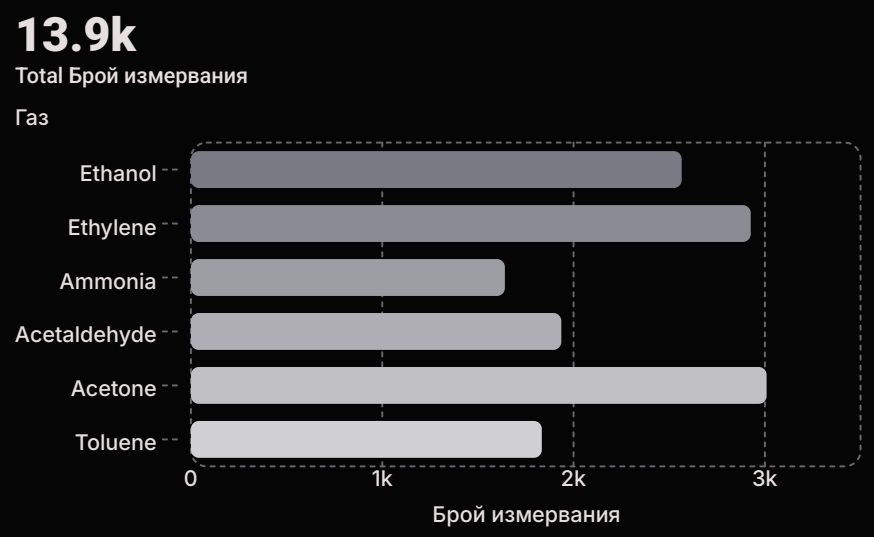

Баланс на датасета

Класовете не са **напълно равномерно разпределени**, но всеки газ има достатъчно представени измервания за обучение и оценка на модела.

Най-много записи има за Acetone и Ethylene, а най-малко за Ammonia и Toluene. Въпреки тези разлики, дисбалансът не е толкова силен, че да изисква специална корекция като oversampling или class weights.

Разликите в броя измервания отразяват реалните условия на събиране на данните, но не пречат на обучението, тъй като всички класове са достатъчно добре представени.

МЕТОДОЛОГИЯ

Използвани модели

Random Forest Classifier

Baseline модел - ансамблов метод, базиран на множество дървета на решения. Робастен, интерпретируем и подходящ за таблични данни с много признаци.

FastAI Tabular Learner

Допълнителен подход - deep learning модел за таблични данни, подходящ за бъдещо сравнение с baseline резултатите.

Random Forest е използван като основен работещ модел за демонстрация, а **FastAI Tabular Learner** е включен като възможно разширение за сравнение с deep learning подход.

РЕЗУЛТАТИ

Резултати от Random Forest

Accuracy

Обща точност на класификация

Precision

Средна стойност по класове

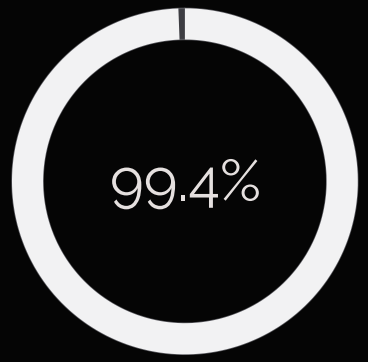

Recall

Средна стойност по класове

F1-Score

Средна стойност по класове

Високите резултати показват, че сензорните данни съдържат достатъчно информативни признаци за разграничаване на различните газове. **Random Forest** моделът постига **99.42% accuracy**, като всички шест класа са разпознати с много висока точност.

АНАЛИЗ

Confusion Matrix — Интерпретация

	Етанол	Етилен	Амоняк	Ацетон	Толуен
Етанол	98.7%	0.0%	0.5%	0.0%	0.0%
Етилен	99.2%	99.2%	0.0%	0.0%	0.0%
Амоняк	0.0%	98.9%	0.0%	0.0%	0.0%
Ацеталдехид	0.0%	0.0%	99.1%	0.0%	0.0%
Ацетон	0.0%	0.0%	0.0%	98.8%	0.4%
Толуен	0.0%	0.0%	0.0%	0.0%	99.3%

Висока точност: над 98% за всички газове.
Минимални грешки между химически сходни класи.

Какво показва матрицата?

Диагоналните елементи доминират - почти всички измервания са класифицирани **правилно**.

Грешките са минимални и се разпределят между малък брой класове, например **Acetaldehyde**/**Toluene**, **Ammonia**/**Acetone** и **Ethylene**/**Acetone**.

Добрата разделимост между класовете потвърждава качеството на сензорния масив и ефективността на признаците.

ЗАКЛЮЧЕНИЕ

Изводи и бъдещо развитие

Доказана ефективност

Проектът демонстрира, че ML може успешно да се прилага върху данни от IoT сензорни мрежи с много висока точност.

Практическо приложение

Подходът е директно приложим при мониторинг на въздуха, индустриална безопасност и откриване на опасни газове.

Бъдещи направления

Тестване с допълнителни модели, анализ на sensor drift, откриване на аномалии и реалновремеви IoT сценарии.